

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ	4
1.1 Задача обнаружения и прогнозирования ошибок и сбоев на станке лазерной резки Навигатор	4
1.1.1 Описание комплекса Навигатор КС-12В	4
1.1.2 Проблема диагностики неисправностей	10
1.1.3 Автоматическое обнаружение неисправностей как ре- шение проблемы диагностики неисправностей	11
1.1.4 Описание подхода к решению задачи автоматической диагностики	12
1.1.5 Временные ряды	13
1.1.6 Интеллектуальный анализ данных временных рядов .	15
1.2 Анализ существующих решений задачи обнаружения и про- гнозирования неисправностей в устройствах	18
1.3 Постановка решаемых задач	22
1.4 Выводы	23
2 ОПИСАНИЕ МЕТОДОВ И ИНСТРУМЕНТОВ ДЛЯ РЕАЛИЗАЦИИ	24
2.1 Система для промышленного интернета вещей	24
2.2 Модель выявления признаков	27
2.3 Выводы	30
ЗАКЛЮЧЕНИЕ	31
СПИСОК ЛИТЕРАТУРЫ	32

ВВЕДЕНИЕ

Основная цель преддипломной практики – теоретический анализ существующих методов для обнаружения и прогнозирования ошибок на устройствах. Данный анализ необходим для решения поставленной задачи в дипломной работе, которая заключается в прогнозировании неисправностей в станках лазерной резки Навигатор КС-12В фирмы ВНИТЭП.

Для решения обозначенной проблемы необходимо провести анализ предметной области, а именно предоставить функциональное и модульное описание станка Навигатор. Кроме этого, необходимо дать мотивировку проблемы автоматического обнаружения неисправности на станках данной модели. Также, в работе необходимо провести анализ существующих актуальных решений для похожих задач прогнозирования и обнаружения неисправностей. Для каждого решения необходимо привести критику в виде выявленных преимуществ и недостатков каждого метода и подхода.

Еще одной задачей преддипломной практики является определение места разрабатываемого решения в существующую систему компании Omnicube, с последующим коротким ее описанием.

В процессе прохождения преддипломной практики необходимо освоить следующие компетенции:

- ОК-7 Способностью к самоорганизации и самообразованию;
- ОПК-5 Способностью решать стандартные задачи профессиональной деятельности на основе информационной и библиографической культуры с применением информационно - коммуникационных технологий и с учетом основных требований информационной безопасности.
- ПК-3 Способностью обосновывать принимаемые проектные решения, осуществлять постановку и выполнять эксперименты по проверке их корректности и эффективности.

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ

1.1 Задача обнаружения и прогнозирования ошибок и сбоев на станке лазерной резки Навигатор

Основным объектом исследования данной работы является станок лазерной резки Навигатор компании ВНИТЭП. Данный станок установлен в компании Сеспель, занимающейся производством автоцистерн и полуприцепов для различных видов перевозок: бензовозы, зерновозы, самосвальные прицепы, цементовозы и т.д.

Опишем функциональный и модульный состав данного станка, а также обозначим проблему обнаружения и прогнозирования ошибок и сбоев для станка. Кроме этого, опишем подход для решения данной задачи через автоматизацию.

1.1.1 Описание комплекса Навигатор КС-12В



Рисунок 1 – Внешний вид комплекса Навигатор КС-12В

Навигатор КС-12В (рисунок 1) представляет собой комплекс обработки листового металла с волоконным лазером, линейным синхронным двигателем и числовым программным управлением (ЧПУ). Разработкой и поддержкой данного комплекса занимается Российская компания ВНИТЭП. Станок

является основным продуктом данной компании.




Рисунок 2 – Графическое описание основных частей станка

Комплекс состоит из следующих основных модулей (рисунок 2): координатный стол, иттербиевый лазер, компрессор, установку для фильтрации и вентиляции, чиллер. Координатный стол состоит из пульта ЧПУ с программным обеспечением, линейных моторов, линейных шариковых направляющих, кабельных каналов, предохранительных каналов, паллет для сбора технологических отходов, оптической измерительной системы.

Возможности станка покрывают задачи лазерной резки большинства металлов различной толщины, до 30 мм. Основные используемые металлы: бронированная сталь, нержавеющая сталь, цирконий, латунь.

Для работы со станком оператор загружает программу через интерфейс ЧПУ. Загружаемая программа представляет собой набор инструкций для станка, которые выполняет станок для вырезки определенной детали определенного формата.

Объектом дипломной работы является модель описанного станка. В компании Сеспель используются несколько станков данной модели.

Задача дипломной работы будет решаться в контексте системы компа-

нии Omnicube.

Компания Omnicube разрабатывает и предоставляет универсальную платформу для решения разнообразных задач интеллектуального мониторинга на предприятиях различных отраслей: промышленность, интеллектуальные сервисы для зданий, мониторинг персонала, экологический мониторинг, сервисы для предприятий сельского хозяйства, инструменты для медицинских учреждений. [43]

Одним из клиентов компании Omnicube является предприятие Сеспель. Компания Omnicube предоставляет функционал сбора, обработки и отображения данных устройств предприятия: станки, установки, производственные роботы. Сами данные собираются с интегрированных и установленных датчиков этих устройств. Кроме этого, Omnicube предоставляет пользовательский интерфейс для руководства и сотрудников компании Сеспель. На данном интерфейсе отображена статистика по различным параметрам, а также отображены различные статистические показатели.

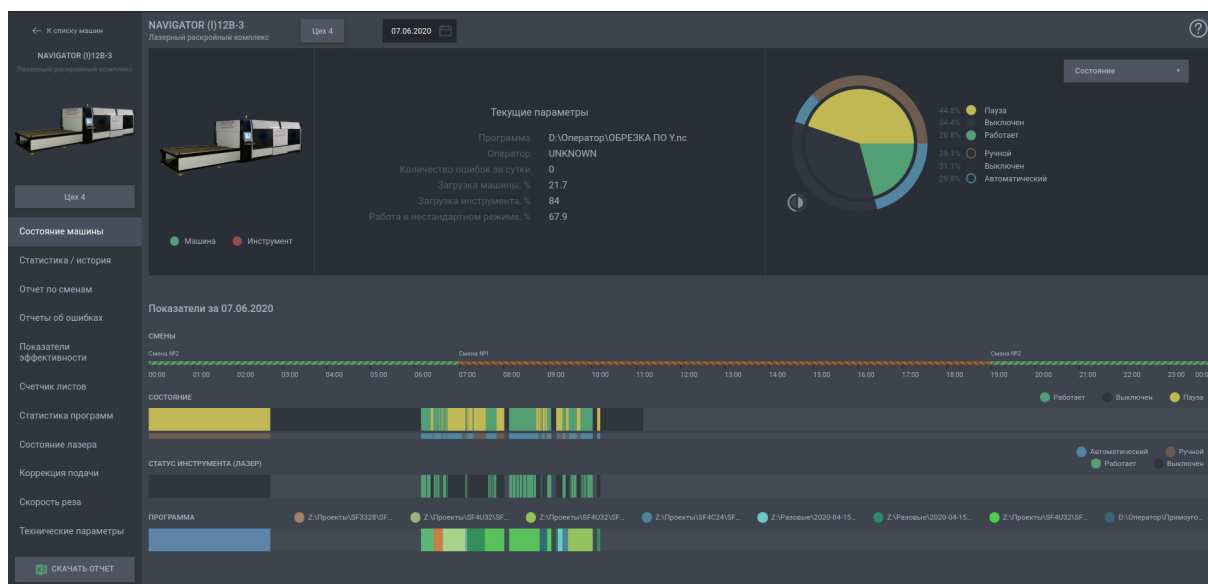


Рисунок 3 – Главные показатели работы станка

Главными показателями (рисунок 3), которые отображаются в интерфейсе являются: состояние, статус лазера, работающая программа. Все показатели записываются относительно рабочий смен сотрудников. Параметр

состояния отображает текущий режим работы станка и представляет собой три режима: рабочий (работа), выключенный (выключен), пауза. Показатель статус инструмента (лазера) отображает статистику по работе лазера станка и может иметь режимы: автоматический, ручной, рабочий, выключенный. Рабочий режим представляет собой использование лазера под присмотром оператора. Кроме этого, основным показателем также является статистика используемых программ для станка.

Вся статистика ведется ежедневно, так как работа ведется посменно. Данную статистику можно проверить в разделе статистика-история. Кроме этого, собирается статистика в виде отчета по сменном каждого оператора.

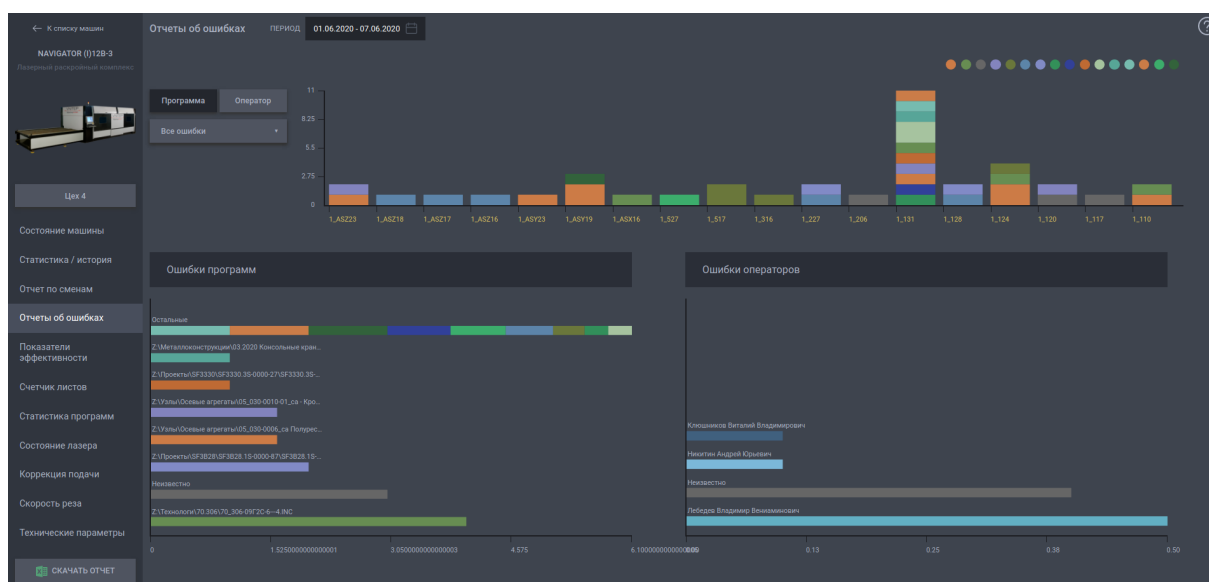


Рисунок 4 – Отчет об ошибках программ и операторов

В разделе «Отчеты об ошибках» (рисунок 4) отображается статистика по неисправностям работающих программ и по ошибкам операторов. В основном графике можно увидеть количество возникновения ошибки (по оси Y), имеющей определенный код (ось X)

Раздел «Показатели эффективности» (рисунок 5) содержит показатели загрузки машины, коэффициента эффективности и коэффициента использования инструмента. Параметр «Загрузка машины» представляет собой время полезной работы. «Коэффициент эффективности» – отношение времени



Рисунок 5 – Показатели эффективности

полезной работы к длительности включения. «Коэффициент использования инструмента» – отношение времени работы инструмента ко времени полезной работы машины. Все показатели выражены в процентах, либо в часах. Также возможно проверить показатели как по сменам, так и по часам.



Рисунок 6 – Статистика счетчика листов

Раздел «Счетчик листов» (рисунок 6) отображает статистику по количеству загружаемых в станок металлических листов. Для просмотра статистики можно выбрать желаемый период.




Рисунок 7 – Статистика по используемой мощности лазера




Рисунок 8 – Статистика по температуре источника

Раздел «Состояние лазера» содержит три показателя по состоянию лазера в течение использования: отношение фактической мощности лазера к заданной, мощность фактическая и установленная (рисунок 7), температура источника лазера (рисунок 8).

Кроме этого есть еще разделы: «Статистика программ» – статистика по используемым программам; «Коррекция подачи» – отклонение по программам и операторам; «Скорость реза» содержит данные по скорости реза, коррекции скорости реза, а также данную статистику относительно программ и операторов. Также можно ознакомиться с основными техническими характеристиками данного станка, а также загрузить отчет в формате .xls, в котором

будет содержаться вся статистика по всем показателям за обозначенный промежуток.

1.1.2 Проблема диагностики неисправностей

Эффективная эксплуатация промышленных устройств требует наличия надежных обслуживающих систем, которые должны предоставлять безопасные, отказоустойчивые решения, поэтому предотвращение ошибок и сбоев имеет первостепенное значение.

Обычно, чтобы предотвратить сбои и ошибки, операторы, как правило, выполняют техническое обслуживание на основе рекомендаций производителей, и им приходится регулярно проверять критически важные детали. Для этого требуются опытные специалисты с высоким уровнем квалификации. Данный процесс очень дорог и трудоемок.

Данная проблема присутствует и на станках модели Навигатор. Регулярно возникают ситуации ошибок программного обеспечения и работы операторов, а также возможны критические сбои, которые заключаются в отказе оптической системы (лазера). Также возможен износ оборудования, например, сбой привода оси XYZ.

На данный момент операторам необходимо постоянно следить за состоянием станка, проводить сложный технический анализ, который может потребовать дополнительных специалистов. Как уже говорилось, такой подход может занять много времени, а также потребовать немало денежных ресурсов. Такой подход является единственным для станков Навигатор.

1.1.3 Автоматическое обнаружение неисправностей как решение проблемы диагностики неисправностей

Целью данной дипломной работы является создание системы для обнаружения и прогнозирования неисправностей на станках лазерной резки Навигатор. Решение данной задачи представляет собой разработку и внедрение данной системы, а также описание теоретического обоснования.

Решение поставленной задачи принесет положительные результаты как для компании ВНИТЭП, так и для ее клиентов, в том числе для предприятия Сеспель, а именно такое решение может сократить время операторов и инженеров, тем самым будут сэкономлены денежные и другие ресурсы предприятия. Разрабатываемое решение повысит эффективность промышленных процессов предприятия Сеспель.

Основными средствами для решения поставленной задачи будет собранная за период 2017-2019 статистика по различным параметрам различных модулей: ЧПУ, лазер, составные части.

Основными метриками будут:

- Отношение заданной мощности лазера к фактической, которое позволит отслеживать тренд износа головы лазера;
- Температура лазера – параметр, который может также быть признаком износа лазерной головы, а также может быть предупреждающим параметром о возможном отклонении от нормы необходимой температуры, что может классифицироваться как ошибка оператора или ошибка станка в целом;
- Данные с датчиков вибрации – позволяют отследить тренд изнашивания платформы станка;
- Данные с датчиков привода XYZ – позволяют определить ошибки и сбои пространственного привода лазера.

1.1.4 Описание подхода к решению задачи автоматической диагностики

В последнее время получила свое распространение парадигма промышленного интернета вещей, являющаяся частью более общего понятия – интернета вещей, которая предоставляет идеи объединения промышленного оборудования и датчиков в единую систему. Такая система может позволить проводить автоматизированный мониторинг и анализ критически важных параметров промышленных устройств, без участия операторов, для обнаружения и предсказания ошибок и сбоев [25].

Не смотря на то, что парадигма промышленного интернета вещей предоставляет идеи для создания системы, она не дает описания способов и методов реализации этой системы. Такое положение обусловлено относительно недавним появлением данной парадигмы, из-за чего еще не устоялась методология и принципы разработки.

Так как на данный момент нет устоявшихся концепций, ведутся разработки на основе различных подходов, при этом учитывается специфика промышленных устройств, для которых разрабатывается система.

Проблему разработки системы промышленного интернета вещей можно разбить на две подпроблемы, каждую из которых можно решать отдельно, однако решение второй подпроблемы может зависеть от решения первой:

1. Разработка подсистемы сбора, обработки и хранения данных с различных устройств;
2. Разработка подсистемы анализа данных для обнаружения и предсказания ошибок и сбоев.

Решение первой подпроблемы может стать основной для решения второй подпроблемы, так как для анализ данных требует наличие готовой среды, в которой будет происходить анализ.

Если первая подпроблема может быть решена проектированием грамотной архитектуры и выбора подходящих инструментов, то для решения второй задачи необходимо определиться с подходами и методами получения прогнозов ошибок и сбоев, с учетом особенностей данных.

Можно сказать, что для того, чтобы иметь систему обнаружения и прогнозирования ошибок и сбоев устройств, нужно решить две поставленные подпроблемы. Первая подпроблема не является темой данной дипломной работы и выходит за ее рамки, однако, в работе будет описана с учетом преимуществ и недостатков существующая разработанная система, в контексте которой будет решаться вторая подпроблема.

1.1.5 Временные ряды

Проблему предсказания и обнаружения ошибок и сбоев на станках можно охарактеризовать как задачу анализа временных рядов, так как основные данные представляют собой последовательность событий, разграниченных по времени.

Временные ряды – серия точек данных, индексированных во временном порядке. Анализ временных рядов представляет собой совокупность методов анализа данных временных рядов, которые направлены на выявление значимых паттернов [7] .

Временные ряды имеют темпоральную структуру, то есть упорядочены во времени, тем самым анализ временных рядов отличается от перекрестных исследований, в которых обычно используется анализ выборки или выборок из генеральной совокупности в определенный момент времени. Кроме этого, анализ временных рядов отличается от пространственного анализа, который имеет такую же фиксированную основу как и перекрестные исследования, например, в пространственном анализе могут анализироваться географические объекты, без учета временной компоненты [14] .

Существует классификация временных рядов [11] :

- одномерные и многомерные;
- стационарные и нестационарные;
- линейные и нелинейные.

Пусть есть процесс x_t , где $t \geq 0$ или $-\infty < t < \infty$.

Одномерные представляют собой временной ряд, которые генерируются на основе одного атрибута, а многомерный имеет больше одного, другими словами в одномерном случае x_t представляет собой вектор, а в многомерном x_t определяется как матрица.

Данные временного ряда можно представить в виде $n \times d$ матрицы данных [8]:

$$\mathbf{D} = \begin{pmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,d} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,d} \end{pmatrix} \quad (1)$$

Вектор-строки вида:

$$\mathbf{x}_i = (x_{i,1}, \dots, x_{i,d}) \quad (2)$$

в зависимости от предметной области имеют различные названия, например: сущности, объекты, примеры и т.д.

Вектор-столбцы вида:

$$\mathbf{X}_j = (x_{1,j}, \dots, x_{n,j}) \quad (3)$$

также могут иметь различные названия: атрибуты, свойства, переменные и т.д.

Стационарность определяется через требование равносильности совместных распределений вектора $(x_{t_1}, \dots, x_{t_k})$ и вектора $(x_{t_1+t}, \dots, x_{t_k+t})$. Другими словами, в стационарном временном ряде есть повторяющиеся паттерны, в отличие от нестационарного [6] .

Линейные модели определяются через свойства линейности параметров временного ряда, например среднего и дисперсии. Нелинейные модели напротив могут иметь нелинейную структуру, что требует использования нелинейных методов, например, методов нелинейной регрессии [5] .

Самыми малоизученными являются нелинейные нестационарные модели [15] . Примеры реализации системы обнаружения и предсказания ошибок, основанные на данном типе моделей не были найдены и обсуждаться в данной работе не будут, так как данная область выходит за рамки темы дипломной работы.

Обозначенную выше подзадачу можно разбить также на два элемента:

1. выявление ошибок, обнаружение аномалий;
2. предсказание поведения устройства.

Данные задачи можно решать как отдельно, где для каждой задачи будет использоваться свой метод, так и совместно через один метод. Каждый вариант будет рассмотрен в существующих примерах.

1.1.6 Интеллектуальный анализ данных временных рядов

Также можно сказать, что поставленная задача обнаружения и предсказания ошибок и сбоев является задачей интеллектуального анализа данных, а именно интеллектуального анализа данных временных рядов. Такое абстрагирование обосновано, так как существуют аналогичные задачи, которые решаются именно с использованием данной парадигмы.

Интеллектуальный анализ данных (data mining) – процесс выявления паттернов из больших объемов данных [19] .

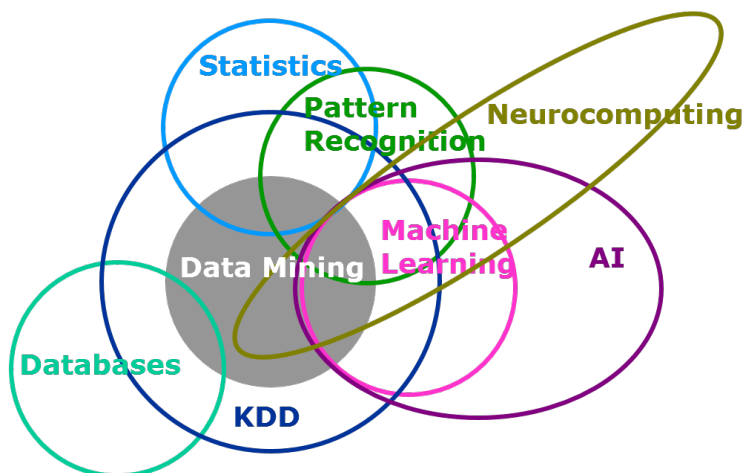


Рисунок 9 – Место интеллектуального анализа данных среди других областей

Интеллектуальный анализ данных представляет собой междисциплинарную область, в которой используются методы, идеи и принципы из следующих областей (рисунок 9): статистика, машинное обучение, распознавание образов, вычислительная нейробиология, базы данных. Стоит отметить, что данная область является частью более широкой области, которая называется выявление (обнаружение) знаний из баз данных (knowledge database discovery).

Кроме этого, интеллектуальный анализ данных можно определить как часть распознавания образов/паттернов (pattern recognition), которая связана с обработкой данных из баз данных и выявлением паттернов, связанных с определенной предметной областью [16] . Сама область распознавания образов покрывает и другие области, например, обработка сигналов и машинное зрение [17] .

Опишем приведенные области, обозначим их основные идеи и принципы.

База данных – организованная коллекция данных, которая собирается и хранится при помощи компьютерных систем. Для взаимодействия поль-

зователя с базой данных используется система управления базами данных (СУБД).

Теория баз данных предоставляет формализованные методы и принципы проектирования и разработки баз данных и СУБД. Обычно теоретически выделяют два главных типа построения баз данных: реляционные (SQL) и нереляционные базы данных (NoSQL). Также иногда выделяют смешанный тип, появившейся сравнительно недавно: новые реляционные базы данных, который совмещает лучшие идеи и принципы из реляционных и нереляционных теорий и подходов (NewSQL) [3] .

В контексте интеллектуального анализа данных базы данных используются как источник данных. Сами данные перед анализом обрабатываются, что также является частью процесса обнаружения знаний. От типа и особенностей сбора и хранения данных в базе зависят последующие шаги анализа данных.

Обнаружение знаний из баз данных (knowledge database discovery, KDD) – более широкая область работы с данными из баз данных, частью которой является интеллектуальный анализ данных. KDD определяют как процесс выявления знаний (паттернов), который разбит на основные шаги [42] :

1. селекция – выборка данных из баз данных по определенным критериям;
2. обработка (pre-processing) – приведение выбранных данных в подходящий вид (очистка и удаление пропущенных значений, фиксирование атрибутов) для последующего анализа;
3. трансформация (transformation) – трансформация данных в подходящую структуру данных, например, в матрицу данных (1);
4. интеллектуальный анализ данных (data mining) – обнаружение паттернов в данных;

5. интерпретация и оценка (interpretation and evaluation).

Следующим шагом также может быть использование, развертывание и эксплуатация обнаруженных знаний и паттернов для целей предметной области.

Статистика, распознавание образов и машинное обучение являются поставщиками методов для каждого шага процесса KDD. Каждая из этих областей имеет свои особенности, однако все они имеют также много общего.

1.2 Анализ существующих решений задачи обнаружения и прогнозирования неисправностей в устройствах

Итак, рассмотрим существующие решения для обнаружения аномалий, например, ошибок и сбоев в данных, а также подходы к прогнозированию и оповещению об этом пользователей.

Во-первых, можно сказать, что модели прогнозирования временных рядов, такие как авторегрессивная модель (AR), модель скользящего среднего (MA), экспоненциальная модель, модель авторегрессии скользящего среднего (ARMA), интегрированная авторегрессионная модель скользящего среднего (ARIMA), зависят от параметров, полученных из исторических временных рядов. Эти параметры являются неотрицательными целыми числами, которые относятся к порядку авторегрессионной части, степени участвующей первой разности и порядку части скользящей средней. Хотя эти процессы могут обрабатывать нестационарные данные, они ограничены в запоминании любого состояния за любой промежуток времени [13].

В [26] авторы рассмотрели потоковые данные как частично наблюдаемый Марковский процесс [27]. Такое решение было принято с целью создания композиционной системы, которая состояла из различных моделей: экспоненциальные модели, сезонные модели, модель лог-гауссовского процесса Кокса. Данная статья содержит хорошие идеи использования фильтров

на композиции частично наблюдаемых Марковских процессов, а также теоретического обоснования такого использования. Однако, хорошая разработанная теория и слабое тестирование на реальных данных не показало высокой эффективности такого подхода. В данной статье авторы научились только предсказывать аномалии, но не смогли их определить, а также использовать данный подход в реальном времени.

Федеративное обучение – один из это методов машинного обучения, который состоит в обучении алгоритма на нескольких децентрализованных периферийных устройствах или серверах, содержащих локальные выборки данных, без обмена их выборками данных. Использование федеративного обучения для фильтрации данных сети медицинских устройств было рассмотрено в [28]. Благодаря использованию методов федеративного обучения, авторам удалось повысить энергоэффективность обработки и анализа данных, то есть они решили одну из самых распространенных проблем в сфере интернета вещей. Также в статье описаны этапы локального анализа данных на самих устройствах и глобального анализа данных на сервере. Для первого этапа авторы использовали адаптивные фильтры [29], для второго матричный анализ возмущений [30]. Недостатком такого подхода является низкая гибкость, так как может потребоваться использовать корреляционный анализ устройств, а в распределенном анализе корреляция может быть утрачена, тем самым будут утрачены полезные признаки. Кроме этого, существуют усовершенствованные адаптивные фильтры, например ядерный рекурсивный фильтр [31]. Еще можно сказать, что матричный анализ возмущений может не учитывать асинхронную структуру предобработанных данных.

В целях мониторинга профиля и обнаружения неисправностей в [32] авторы применили модель нелинейной параметрической регрессии для разработки системы, которая была бы устойчивой и нечувствительной к изменениям температуры в производственной практике. В [33] был разработан метод мониторинга, который может автоматически адаптировать параметры

контрольной карты (метод из теории управления). В [34] авторы добавили все профили каналов и применили анализ главных компонент (РСА) агрегированным профилям тоннажа для извлечения характеристик. В [35] использовались как статистические, так и вейвлет-характеристики, извлеченные из сигналов датчиков, для разработки адаптивного метода обучения для оценки износа инструмента в процессе высокоскоростного фрезерования. Каждое из этих исследований было сосредоточено на анализе индивидуального профиля данных, то есть анализ был проведен с одномерными данными. Однако, выходы датчиков устройства обычно являются многоканальными, что требует многомерного анализа временных рядов.

У многомерных данных могут быть следующие особенности [10]:

- С увеличением числа датчиков обработка каждого временного ряда от каждого датчика становится как более интенсивной, что сказывается на повышении вычислительной нагрузки;
- Данные имеют больше выбросов и шумов, по сравнению с одномерными данными;
- Временные ряды от разных датчиков имеют корреляции на разных уровнях, что приводит к большому количеству избыточной информации, однако необходимо учитывать возможные корреляции;
- Состояния работы до простоя обычно продолжаются в течение некоторого времени и включают состояния отказа оборудования. Кроме того, после восстановления неисправного датчика также появляется период задержки в рабочем состоянии. Следовательно, модель прогнозирования должна иметь инвариантность памяти относительно таких состояний.

Эти особенности данных приводят к следующим вопросам исследования:

- Как уменьшить избыточную информацию без ухудшения точности прогнозирования?
- Как определить выбросы и шумы?
- Как моделировать долгую память состояний?
- Как точно предсказать текущее состояние на основе исторических данных?

Опишем существующие результаты, которые отвечают на эти вопросы.

Авторы в статье [36] применили многофакторную PCA для уменьшения размерности данных с целью повышения эффективности системы анализа профиля и отслеживания данных многоканального профиля с помощью контрольных диаграмм. Автор статьи [37] извлек набор нескольких функций мониторинга из данных профиля большого размера, чтобы обнаружить износ инструмента. В другой статье [38] автор применил некоррелированный многолинейный анализ главных компонент (UMPCA) [39] для мониторинга профиля и диагностики неисправностей, который учитывал взаимосвязь каналов различных профилей. По сравнению с UMPCA, основанной на PCA, линейный дискриминантный анализ (LDA) также является классическим методом выделения признаков в данных. Однако обычный LDA не может работать с многомерными данными напрямую, потому что это метод предназначен для одномерных задач.

В статье [40] был предложен некоррелированный мультилинейный дискриминантный анализ для распознавания лиц и обработки изображений. Такой анализ напрямую работает с многомерными данными и извлекает некоррелированные дискриминантные признаки посредством проекции тензор вектор. По сравнению с алгоритмом UMPCA, который не контролируется, такой метод представляет собой контролируемый мультилинейный экстрактор признаков, который будет учитывать информацию о классе при извлечении

объектов и может быть более подходящим для распознавания лиц. Несмотря на то, что есть некоторые предварительные исследования по применению UMLDA для распознавания лиц и обработки изображений, в литературе опубликовано мало исследований по использованию технологии UMLDA для анализа многомерных данных для автоматического управления процессом в промышленных системах. В [41] авторы предложили решение проблемы обнаружения неисправностей в реальном времени на основе объединения многомерных данных временных рядов в модели UMLDA, однако авторы не смогли до конца достичь высокой эффективности, которые предоставляют другие методы.

1.3 Постановка решаемых задач

Как уже было обозначено выше, основной целью дипломной работы является создание системы для обнаружения и прогнозирования неисправностей на станках лазерной резки Навигатор КС-12В компании ВНИТЭП, установленных на предприятии Сеспель.

Основной гипотезой является достижение цели через методы интеллектуального анализа данных многомерных временных рядов.

Окончательно определим задачи, которые необходимо решить:

1. обработка и подготовка накопленных данных со станка Навигатор;
2. выбор и обоснование выбора модели кластеризации в данных;
3. аннотирование кластеров;
4. выбор обучающейся на данных модели для обнаружения неисправностей;
5. выбор и обоснование выбора модели для предсказания многомерных временных рядов данных станка;

6. выбор оптимального размера окна для обучения;
7. выбор оптимального размера окна для предсказания;
8. реализация моделей и тестирование моделей;
9. интеграция моделей в систему компании Omnicube.

1.4 Выводы

В данной разделе была обозначена проблема выявления ошибок и сбоев на станках лазерной резки модели Навигатор КС-12В, а также в устройствах вообще. Были описаны особенности данной проблемы, а также ее теоретические аспекты. Кроме этого, был проведен анализ существующих решений, базирующихся на различных методах, подходах и идеях. Для каждого случая была дана критика, а именно обозначены достоинства и недостатки каждого решения.

В конце главы были обозначены задачи, решения которых может помочь достичь решения проблемы выявления ошибок и прогнозирования.

2 ОПИСАНИЕ МЕТОДОВ И ИНСТРУМЕНТОВ ДЛЯ РЕАЛИЗАЦИИ

2.1 Система для промышленного интернета вещей

Как было описано в предыдущем разделе 1, промышленный анализ данных предоставляет идеи для создания интеллектуальной системы для автоматизации и повышения эффективности работы промышленных устройств. Одной из множества компаний, которая ведет деятельность в данной области, является компания Omnicube, которая, как уже говорилось, имеет свою универсальную систему для множества задач не только промышленного интернета вещей, но интернета вещей в общем, то есть задачи, решаемые данной системой, не ограничиваются промышленной отраслью. Реализация решения для обнаружения и прогнозирования неисправностей решается в контексте данной системы. Опишем данную систему.

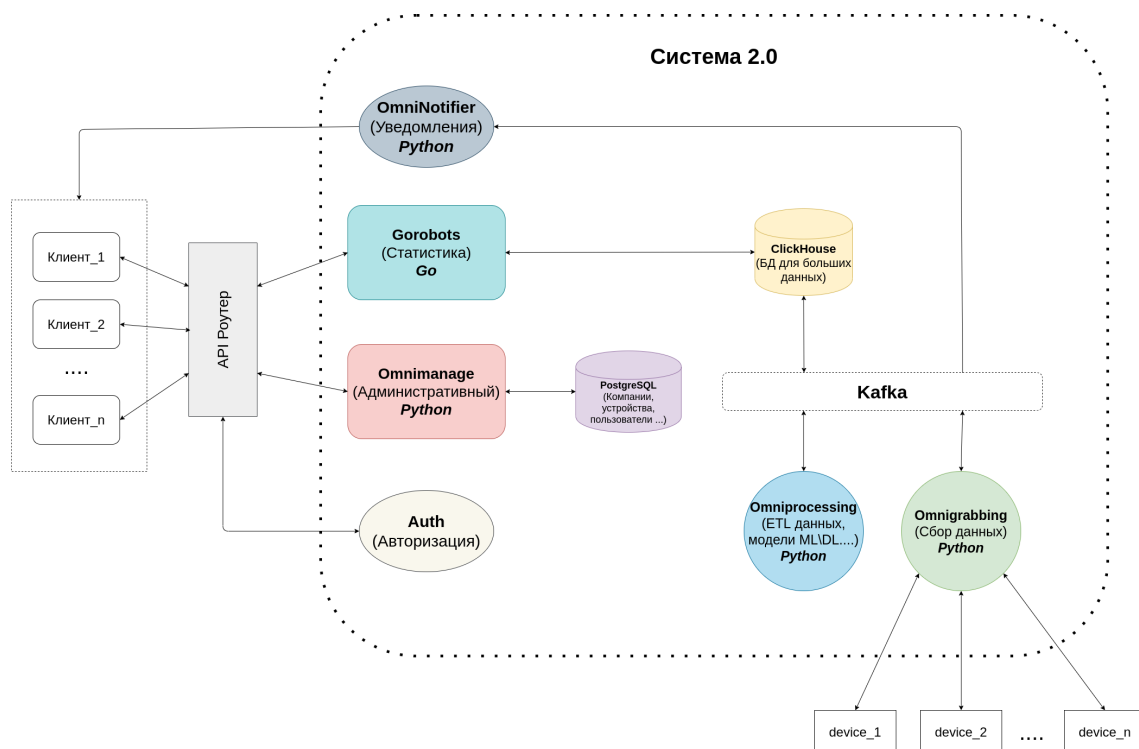


Рисунок 10 – Разработанная система для интернета вещей

Данная система имеет микросервисную архитектуру. Микросервисная

архитектура представляет собой рассмотрение разрабатываемого приложения как совокупности связанных сервисов, каждый из которых отвечает за какую-то часть общей системы, а также решает свою определенную задачу. Такой подход имеет свои преимущества и недостатки. Основным преимуществом является модульность, которая позволяет разрабатывать и поддерживать компоненты независимо друг от друга. Недостатками являются: высокая сложность разработки, сложный процесс развертывания системы на собственных кластерах, и, особенно, на кластерах клиентов.

Основными взаимодействующими с системой структурами являются клиенты и устройства клиентов. Каждое клиентское устройство соединяется с системой при помощи инженеров компании Omniscube с учетом специфики самих устройств. Например, для станков лазерной резки Навигатор использовались датчики, которые устанавливались на критически важные узлы, с которых собиралась необходимая информация. Помимо этого, сами устройства клиентов иногда предоставляют функционал, который позволяет собирать данные без установки датчиков. Далее, данные устройств агрегируются и обрабатываются также с учетом специфики устройств. Обработанные данные выдаются клиентам в виде пользовательского интерфейса, примером которого является интерфейс для предприятия Сеспель с данными станка лазерной резки Навигатор.

Главными узлами системы являются два микросервиса: omnimanage и gorobots. Микросервис omnimanage отвечает за обработку первичных данных клиента: сведения о клиенте, сведения о пользователях компании клиента, сведения об устройствах клиента (но не сами данные устройств), сведения о ролях пользователей для авторизации и т.д. Gorobots отвечает за обработку собранной с устройств статистики: вычисляет основные статистические показатели (среднее, дисперсию, КПД). Omnimanage написан на языке Python с использованием базы данных PostgreSQL. Gorobots написан на языке Go, данные в этом микросервисе берутся из базы данных ClickHouse.

Микросервис omnigrabbing отвечает за сбор и первоначальную обработку данных клиентских устройств. в данном микросервисе происходит конвертация в необходимых формат для отправления данных в Kafka, и последующую загрузку в ClickHouse.

Kafka – платформа для обработки потоковых данных в реальном времени. Проект направлен на создание унифицированной высокопроизводительной платформы с низкой задержкой для обработки потоков данных в реальном времени. Kafka использует двоичный протокол на основе TCP, а также системы для обработки асинхронных данных. Такой брокер был выбран по причине большого количества поступающих данных. Kafka позволяет гибко решать задачи обработки большого количества асинхронных данных [44].

ClickHouse - это быстрая система управления базами данных OLAP с открытым исходным кодом. Данная система ориентирована на столбчатую структуру, а также позволяет генерировать аналитические отчеты с использованием SQL-запросов в режиме реального времени. База данных была выбрана по причине высокой нагрузки, заключающейся в необходимости хранить большое количество данных. Данная СУБД позволяет обрабатывать несколько тысяч запросов в секунду, что является ключевой особенностью, которая выделяет данную систему среди других конкурентов [45].

В системе компании Omnicube также присутствуют вспомогательные микросервисы:

- API роутер – система для перенаправления запросов клиентов;
- Auth – сервис для авторизации пользователей;
- OmniNotifier – система для оповещения клиентов.

Микросервис omniprocessing является местом, где располагаются различные модели для мониторинга и обработки данных, например, модели ма-

шинного обучения. Основные цели данного микросервиса – извлечение, трансформация и загрузка.

В omniprocessing используется Python фреймворк Faust, который позволяет отправлять данные в очередь брокеру сообщений Kafka. Из Kafka данные попадают в базу данных ClickHouse. Благодаря данному фреймворку можно быстро строить и встраивать пайплайны машинного обучения [46]. Разрабатываемое решение для станков Навигатор располагается именно в микросервисе omniprocessing.

2.2 Модель выявления признаков

Основным компонентом системы обнаружения и прогнозирования неисправностей является модель для кластеризации, основанная на алгоритме t-Shape.

Среди всех методов, применяемых к данным временных рядов, кластеризация является наиболее широко используемой, поскольку она не зависит от дорогостоящего человеческого наблюдения или отнимания времени, требующего больших затрат времени. С помощью кластеризации возможно идентифицировать и обобщить интересные закономерности и корреляции в базовых данных. В последние несколько десятилетий, кластеризация последовательностей временных рядов получила значительное внимание, не только как мощный самостоятельный исследовательский метод, но и также как шаг предварительной обработки или подпрограмма для других задач. Большинство методов анализа временных рядов, включая кластеризацию, критически зависят от выбора меры расстояния. Ключевой вопрос при сравнении двух последовательностей временных рядов заключается в том, как обрабатывать различные искажения, которые будут обсуждаться, которые характерны для последовательностей.

Из-за этих трудностей и различных потребностей в инвариантности из

одной области в другую большее внимание уделялось созданию новых мер расстояния, а не созданию новых алгоритмов кластеризации. Обычно считается, что выбор меры расстояния более важен, чем сам алгоритм кластеризации. Как следствие, кластеризация по временным рядам основывается главным образом на классических методах кластеризации: либо путем замены расстояния по умолчанию на более подходящее для временных рядов, либо путем преобразования временных рядов в «плоские» данные, чтобы существующие алгоритмы кластеризации могут быть использованы непосредственно. Однако выбор метода кластеризации может повлиять: на точность, так как каждый метод выражает однородность и разделение кластеров по-разному; и эффективность, поскольку вычислительные затраты отличаются от одного метода к другому. Например, спектральная кластеризация или некоторые варианты иерархической кластеризации [30] являются более подходящими для идентификации кластеров на основе плотности (т. Е. Областей с более высокой плотностью, чем оставшаяся часть данных), чем методы разделения, такие как k-средних [30] или k-медоиды [30]. С другой стороны, k-means более эффективен, чем иерархические, спектральные или k-medoids методы.

К сожалению, современные подходы к кластеризации на основе форм, в которых используются методы разбиения с мерами расстояния, не зависящими от масштаба и сдвига, имеют два основных недостатка: (i) эти подходы не могут масштабироваться до больших объемы данных, поскольку они зависят от вычислительно дорогостоящих методов или мер расстояния; (ii) эти подходы были разработаны для конкретных доменов или их эффективность была показана только для ограниченного числа наборов данных. Более того, наиболее успешные методы кластеризации на основе форм обрабатывают фазовую инвариантность посредством локального нелинейного выравнивания координат последовательности, даже если глобальное выравнивание часто является адекватным. Например, для набора данных ЭКГ эффективный

линейный дрейф может выявить основные различия в шаблонах последовательностей двух классов, в то время как дорогостоящее нелинейное выравнивание может соответствовать каждому соответствующему увеличению или падению каждой последовательности, что затрудняет различать два класса.

Важно отметить, что, насколько известно, эти подходы никогда не подвергались всесторонней оценке друг против друга, против других методов разделения или против различных подходов, таких как иерархические или спектральные методы. В статье [31] авторы предложили новый алгоритм k-Shape для кластеризации временных рядов на основе форм, который эффективен и не зависит от конкретной системы. k-Shape основан на масштабируемой процедуре итеративного уточнения, аналогичной той, которая используется алгоритмом k-средних, но с существенными отличиями. В частности, k-Shape использует и другую меру расстояния, и другой метод вычисления центроидов, чем метод k-средних. Как указывалось выше, k-Shape пытается сохранить формы последовательностей временных рядов при их сравнении. Для этого k-Shape требуется мера расстояния, которая инвариантна к масштабированию и сдвигу. В отличие от других подходов кластеризации, для k-Shape адаптируется статистическая мера кросс-корреляции

2.3 Выводы

В данном разделе был проведен анализ системы компании Omnicube, в которую будет интегрировано решение для прогнозирования и обнаружения ошибок станков Навигатор.

Кроме этого, был проведен анализ алгоритмов и выбран алгоритм для кластеризации многомерных временных рядов t-Shape. Именно данный алгоритм поможет качественно определять особенности данных временных рядов станка Навигатор, и на основе этих особенностей определять обозначенные неисправности.

ЗАКЛЮЧЕНИЕ

В данном отчете по преддипломной практике были решены ряд задач, связанных с темой дипломной работы:

- проведен анализ предметной области в виде анализа станков лазерной резки Навигатор;
- описана проблема автоматического обнаружения и прогнозирования ошибок и сбоев на станках Навигатор;
- описаны существующие подходы и методы к решению похожих проблем;
- Обозначены задачи, которые необходимо решить для разработки системы;
- описана система компании Omnicube, в которую будет встраиваться разрабатываемое решение по прогнозированию и обнаружению неисправностей на станках Навигатор
- описан алгоритм t-Shape, который является подходящим для решения поставленных задач.

В процессе прохождения преддипломной освоены следующие компетенции:

- ОК-7 Способностью к самоорганизации и самообразованию;
- ОПК-5 Способностью решать стандартные задачи профессиональной деятельности на основе информационной и библиографической культуры с применением информационно - коммуникационных технологий и с учетом основных требований информационной безопасности.
- ПК-3 Способностью обосновывать принимаемые проектные решения, осуществлять постановку и выполнять эксперименты по проверке их корректности и эффективности.

СПИСОК ЛИТЕРАТУРЫ

1. Лоскутов А.Ю. Анализ временных рядов. Курс лекций. – Физический факультет МГУ, 2018. – 113 с.
2. Шитиков В.К. Классификация, регрессия и другие алгоритмы Data Mining с использованием R. – Институт экологии Волжского бассейна РАН, 2017. – 351 с.
3. Мартин Фаулер. NoSQL: новая методология разработки нереляционных баз данных. – Вильямс, 2016. – 192 с. – ISBN 978-5-8459-1829-1.
4. Marc S. Paoletta. Linear Models and Time-Series Analysis. – Wiley, 2019. – 897 с. – ISBN: 978-1-119-43185-5.
5. Douglas C. Montgomery. Introduction to time series analysis and forecasting. – Wiley, 2015. – 671 с.
6. Terence C. Mills. Applied Time Series Analysis. A practical guide to modeling and forecasting. – Academic press, 2019. – 356 с. – ISBN: 978-0-12-813117-6.
7. George Box. Time series analysis. Forecasting and control. – Wiley, 2016. – 709 с. – ISBN 978-1-118-67502-1.
8. Mohammed J. Zaki. Data mining and analysis. // Fundamental Concepts and Algorithms. – Cambridge university press, 2018. – 562 с. – ISBN 978-0521766333.
9. Zhiqiang Ge. Multivariate Statistical Process Control. – Springer, 2019. – 203 с. – ISBN 978-1-4471-4513-4.
10. William W.S. Wei. Multivariate Time Series Analysis and Applications. – Wiley, 2019. – 528 с.

11. Zhihua Zhang. Multivariate Time Series Analysis in Climate and Environmental Research. – Springer, 2018. – 293 c. – ISBN 978-3-319-67339-4.
12. Ruey S. Tsay. Multivariate Time Series Analysis. – Wiley, 2016. – 522 c.
13. Kamil Feridun Turkman. Non-Linear Time Series. Extreme Events and Integer Value Problems. – Springer, 2018. – 255 c. – ISBN 978-3-319-07027-8.
14. Robert H. Shumway. Time Series Analysis and Its Applications. With R Examples. – Springer, 2019. – 202 c. – ISBN 978-1-4419-7864-6.
15. Tata Subba Rao. Time Series Analysis: Methods and Applications. – Elsevier, 2017. – 777 c. ISBN: 978-0-444-53858-1.
16. Boris Mirkin. Core Concepts in Data Analysis: Summarization, Correlation and Visualization. – Springer, 2018. – 402 c.
17. Mehmed Kantardzic. Data mining. Concepts, Models, Methods, and Algorithms. – Wiley, 2020. – 661 c.
18. Charu C. Aggarwal. Frequent Pattern Mining. – Springer, 2019. – 85 c.
19. Jiawei Han. Data Mining. Concepts and Techniques. – Morgan Kaufmann Publishers, 2012. – 740 c.
20. Jure Leskovec. Mining of Massive Datasets. – Stanford, 2019. – 513 c.
21. Predictive Statistics. Analysis and Inference beyond Models. – Cambridge University Press, 2018. – 657 c. – ISBN 978-1-107-02828-9.
22. Max Kuhn. Applied Predictive Modeling. – Springer, 2018. – 615 c. – ISBN 978-1-4614-6848-6.
23. Richard Sutton. Reinforcement learning. – The MIT Press, 2018. – 548 c.

24. Mehryar Mohri. Foundations of Machine Learning. – The MIT Press, 2018. – 505 c.
25. Boyes, Hugh. The industrial internet of things (IIoT): An analysis framework. – Computers in Industry, 2018. – 1-12 c.
26. Jonathan Law. Composable models for online Bayesian analysis of streaming data. – Springer Statistics and Computing 28, 2017. – 1119–1137 c.
27. E. L. Ionides, C. Bretó, and A. A. King. Inference for nonlinear dynamical systems. Proceedings of the National Academy of Sciences of the United States of America, 103(49):18438–43, 2016.
28. Sunny Sanyal, Dapeng Wu, and Boubakr Nour. A Federated Filtering Framework for Internet of Medical Things. IEEE International conference on communications (IEEE ICC 2019).
29. Simon Haykin. Adaptive Filter Theory. – Prentice Hall, 2016. – ISBN 0-13-048434-2.
30. G. W. Stewart. Matrix perturbation theory. – Wiley, 2017. – 234 c.
31. Steven Van Vaerenbergh. Kernel Recursive Least-Squares Tracker for Time-Varying Regression. – IEE Transactions on neural networks and learning systems, vol. 23, No 8, 2018.
32. Paynabar K, Jin J, Agapiou J, Deeds P (2012) Robust Leak Tests for Transmission Systems Using Nonlinear Mixed-Effect Models. Journal of Quality Technology 44 (3):265-278
33. Grasso M, Colosimo BM, Tsung F (2017) A phase I multi-modelling approach for profile monitoring of signal data. International Journal of Production Research 55 (15):4354-4377. doi:10.1080/00207543.2016.1251626

34. Lei Y, Zhang Z, Jin J (2016) Automatic Tonnage Monitoring for Missing Part Detection in Multi-Operation Forging Processes. *Journal of Manufacturing Science and Engineering-Transactions of the Asme* 132 (5). doi:10.1115/1.4002531
35. Yang W-A, Zhou Q, Tsui K-L (2016) Differential evolution-based feature selection and parameter optimisation for extreme learning machine in tool wear estimation. *International Journal of Production Research* 54 (15):4703-4721. doi:10.1080/00207543.2015.1111534
36. Grasso M, Colosimo BM, Pacella M (2018) Profile monitoring via sensor fusion: the use of PCA methods for multi-channel data. *International Journal of Production Research* 52(20):6110-6135. doi:10.1080/00207543.2014.916431
37. Zerehsaz Y, Shao C, Jin J (2016) Tool wear monitoring in ultrasonic welding using high-order decomposition. *Journal of Intelligent Manufacturing* 30 (2):657-669. doi:10.1007/s10845-016-1272-4
38. Paynabar K, Jin J, Pacella M (2017) Monitoring and diagnosis of multichannel nonlinear profile variations using uncorrelated multilinear principal component analysis. *IIE Transactions* 45 (11):1235-1247. doi:10.1080/0740817x.2013.770187
39. Lu H, Plataniotis KN, Venetsanopoulos AN (2019) Uncorrelated Multilinear Principal Component Analysis for Unsupervised Multilinear Subspace Learning. *IEEE Transactions on Neural Networks* 20 (11):1820-1836. doi:10.1109/tnn.2009.2031144
40. Lu H, Plataniotis KN, Venetsanopoulos AN (2019) Uncorrelated Multilinear Discriminant Analysis With Regularization and Aggregation for Tensor

- Object Recognition. IEEE Transactions on Neural Networks 20 (1):103-123.
doi:10.1109/tnn.2008.2004625
41. Feng Ye, Zhijie Xia, Min Dai, Zhisheng Zhang Real-Time Fault Detection and Process Control Based on Multi-channel Sensor Data Fusion. Journal of Intelligent Manufacturing, 2020.
 42. Data Mining Curriculum. – ACM SIGKDD Curriculum Committee, 2016. – 10 с.
 43. Сайт компании Omnicube [Электронный ресурс]. – Режим доступа: <https://www.omnicube.ru/>, свободный. – (01.06.20)
 44. Официальная документация Kafka [Электронный ресурс]. – Режим доступа: <https://kafka.apache.org/documentation/>, свободный. – (10.05.20)
 45. Официальная документация ClickHouse [Электронный ресурс]. – Режим доступа: <https://clickhouse.tech/>, свободный. – (10.05.20)
 46. Faust фреймворк [Электронный ресурс]. – Режим доступа: <https://faust.readthedocs.io/en/latest/>, свободный. – (10.05.20)